


Ciencia de Datos y Aprendizaje Automático

Proyecto Final

Embárcate en un viaje
para construir un
sistema inteligente que
transforme nuestra
forma de interactuar con
el conocimiento.

Proyecto Final



“Una aplicación interactiva para navegar por un gran corpus de documentos utilizando **embeddings** y **agrupamiento**.”

Proyecto Final



El proyecto final te ayudará a **desarrollar tu intuición** sobre conceptos como:

- ¿Qué son los embeddings? y ¿cómo se obtienen?
- ¿Cómo podemos visualizar datos de alta dimensionalidad?
- ¿Cómo funciona el aprendizaje por transferencia?
- ¿Qué tipo de patrones parecen aparecer en los datos visualizados? ¿Hay grupos? ¿Cuáles son?
- ¿Cómo podemos detectar anomalías en los datos?
- ¿Cómo podemos usar el aprendizaje automático para hacer predicciones con nuevos embeddings?

Visión General del Proyecto



Construir un sistema inteligente de gestión de documentos que cumpla los siguientes **cuatro requisitos fundamentales**:

- Transformar documentos en representaciones vectoriales
- Crear una base de conocimiento consultable
- Permitir la exploración visual de relaciones entre documentos
- Implementar mecanismos de control de calidad y auto-descubrimiento



Objetivos de Aprendizaje

- Aplicar técnicas de embedding de texto
- Implementar aprendizaje no supervisado para agrupamiento y visualización
- Desarrollar modelos de aprendizaje supervisado para evaluación de calidad
- Construir un pipeline completo de ML desde la ingesta hasta la interfaz
- Ganar experiencia práctica en NLP y visualización

Dominio del Proyecto



A cada sección práctica se le asignará un **dominio específico** sobre el cual trabajar. Tu profesional de la industria comunicará el dominio asignado en clase. Los mecanismos de control de calidad y auto-descubrimiento deben estar **adaptados al dominio asignado**.

Independientemente del dominio, **asegúrate de que los documentos utilizados para el proceso de ingesta sean de acceso abierto!**

No uses documentos con derechos de autor.

Dominio del Proyecto: Dominios Posibles



Ejemplo	Descripción
Sistema de Organización de Papers	Ingerir papers de investigación abiertos. Descubrir grupos útiles de datos. Identificar grupos no relevantes y papers anómalos.
Gestión de Documentación Técnica	Ingerir documentación técnica y referencias de API. Descubrir grupos útiles de datos. Identificar grupos no relevantes y documentos anómalos.
Base de Conocimiento Médico	Ingerir literatura médica abierta y guías. Descubrir grupos útiles de datos. Identificar grupos no relevantes y documentos anómalos.

Tu profesional de la industria confirmará qué dominio corresponde a tu sección.

Requisitos Fundamentales del Sistema



Requisito	Descripción
1. Pipeline de Ingesta de Documentos	• Interfaces de línea de comandos y API • Soporte para documentos texto plano y PDF • Integración de modelo de embedding local
2. Almacenamiento de Base de Conocimiento	• Base de datos vectorial para embeddings • Almacenamiento de metadatos
3. Interfaz de Exploración	• Visualización interactiva de grupos • Capacidades de búsqueda semántica
4. Control de Calidad	• Detección de anomalías • Clasificación de calidad

Stack Tecnológico



Componente	Tecnología
Lenguaje	Python
Modelo de Embedding	Modelo local (ej. all-MiniLM-L6-v1 de Sentence Transformers) con flexibilidad para integrar modelos externos
Base de Datos Vectorial	Chroma u otras BD vectoriales locales
Aprendizaje Automático	scikit-learn, pandas, numpy, PyTorch
Visualización	Matplotlib, Streamlit, y otras bibliotecas
Cumplimiento de código	Black, mypy, y otras herramientas

Arquitectura del Sistema



Una parte importante del proyecto final es **pensar en la arquitectura** de tu sistema basándote en los requisitos fundamentales.

Se proporcionarán y discutirán algunas ideas en las clases magistrales y en las sesiones prácticas.

Cronograma de Desarrollo Propuesto



Semanas 1-2: Configuración y Pipeline Inicial

- Configuración del entorno, exploración de arquitectura, carga de documentos, integración de embeddings

Semanas 3-4: Control de Calidad

- Clasificación, detección de anomalías, búsqueda, demo de mitad de curso

Semanas 5-6: Aprendizaje No Supervisado

- Clustering, visualización, UI/UX

Semana 7: Integración

- Integración del sistema y entrega final



¡Gracias!

Este es el final de la definición del proyecto final.